

参赛学生姓名：于儿 Fisher E. Yu

中学：华南师范大学附属中学

省份：广东省

国家/地区：中国

指导老师姓名：杨晓安，肖天昂

指导老师单位：华南师范大学附属中学，谱蓝云

论文题目：Topological Feature Analysis of Focus
Music Based on Path Homology and Its
Application in ACE-Step Latent Space
Guided Generation

Topological Feature Analysis of focus music Based on Path Homology and Its Application in ACE-Step Latent Space Guided Generation

Fisher E. Yu

September 12, 2026

Abstract

功能性专注音乐被广泛用于学习与工作场景，但其区别于一般音乐的时序结构仍缺少可计算、可审计且可用于生成控制的表示。本文将音乐建模为随时间演化的有向动态系统，在由 300 首 Open Focus 与 300 首 Classical 器乐组成、具有逐曲来源与许可记录的数据集上，采用“发现拟合—冻结—主要验证—时长敏感性”流程，结合 GLMY 路径同调与相位提升路径同调，比较局部状态转移和跨周期相位闭合。validation/180s 的主要分析表明：音高与节奏视角分别有 13/20 和 14/20 个预设指标通过 BH-FDR；Classical 通常具有更广的状态覆盖与转移多样性，而 Open Focus 具有更高的自转移比例和有向复现率。调制视角有 5/20 个指标通过主分析 FDR，但因其 $SMP-K = 10$ 表征是在 holdout 开启后提出，仅作探索性解释。三个局部视角均未获得稳定的 H_1 组间差异。宏观尺度上，Open Focus 的 Acoustic 与 Chroma 相位 loop_score 高于 Classical，rank-biserial 效应量分别为 0.459 与 0.338，且通过三视角 BH-FDR；Rhythm phase 在主要尺度未通过 FDR。多尺度分析显示，Pitch、Phase 及其联合空间均存在组间距离差异，但联合表示并未优于最佳单块。基于上述结果，本文为后续未见数据与生成实验冻结由 16 维 Pitch、Acoustic phase 与 Chroma phase 各一维组成的 18 维指纹，平方距离权重为 $1/2 : 1/4 : 1/4$ 。进一步地，本文在 ACE-Step 1.5 上实现了“精确 Path Homology 教师—可微潜空间代理—精确复核”推理期引导协议：以逐采样步预测干净潜变量的精确拓扑标签训练代理网络，在未见 prompt、seed family 与生成轨迹上完成并通过坐标预测、候选排序、不确定度校准及 OOD/no-op 资格检验，随后以 512 首 baseline/guided 配对音频完成最终评价。该评价以冻结精确拓扑目标带为主要终点，并将 prompt 一致性、音质、多样性、运行时间与显存开销纳入预设非劣性判据，从而形成从观察性结构发现、指纹冻结到门控生成评价的完整证据链。本文结论仅涉及当前语料与冻结协议下的拓扑结构表征和生成控制，不作注意力改善或临床疗效的因果推断。

Keywords: focus music, Topological Music Analysis, Path Homology, Persistent Path Homology, Topology-Guided Music Generation, Latent Topology Surrogate Network, ACE-Step

目录

1	Introduction	4
2	Related Work	5
2.1	音乐拓扑分析	5
2.2	扩散模型生成控制与拓扑约束	6
3	数据集	6
3.1	数据来源	6
3.2	数据切分与治理	6
3.3	数据预处理	7
4	拓扑特征发现与验证	7
4.1	理论基础	7
4.2	分析框架与方法	8
4.3	状态表征	8
4.4	验证结果	9
4.5	多视角融合与消融分析	12
4.6	拓扑指纹冻结	17
5	ACE-Step 拓扑引导音乐生成	18
5.1	研究边界与方法概览	18
5.2	三维精确拓扑教师	18
5.3	预测干净潜变量与时间条件	19
5.4	LTCH-P3 网络结构	19
5.5	教师标签、数据构造与防泄漏	20
5.6	损失函数与训练配置	20
5.7	选择性采样校正与安全回退	21
5.8	资格检验、最终评价与当前状态	21
A	完整特征指标数据	26
A.1	音高视角	26
A.2	节奏视角	27
A.3	调制视角	28

B 致谢	29
C 研究经历	30

1 Introduction

注意缺陷多动障碍（Attention Deficit Hyperactivity Disorder, ADHD）是一类常见的神经发育障碍，全球儿童患病率约为 7 – 10%，成人患病率约为 2 – 5%[1]。保守估计，全球大约有 2.4 亿人不同程度地受到注意力缺失的影响。在学习、写作、编程和深度工作场景中，专注音乐常被用于支持持续注意力。有研究表明，有针对性设计的 focus music 在辅助提升注意力方面展现出了卓越的潜力 [2–4]。

近几年，随着 EEG、fMRI 和大语言模型技术的发展，越来越多的研究开始关注功能性音乐的声学调制、统计特征与注意场景之间的关系。例如，Kevin J. P. Woods 等人系统探讨了音乐的幅度调制（amplitude modulation, AM）特性如何影响持续注意力 [5]。Achuthan 等人通过大规模 Reddit 数据分析，借助 Spotify API 和大语言模型，揭示了 focus music, stuck songs 和 general purpose music 之间的音频特征差异 [6]。

然而，许多基于数据统计或拓扑数据分析（TDA）的音乐特征研究都会弱化事件次序。在音乐理论中，音符或和弦的转移序列具有绝对的时间方向性。例如，“C 大调 → G 大调”与“G 大调 → C 大调”在听觉和心理层面有着本质的区别。顺序和上下文是音乐预期的重要组成部分 [7, 8]，维持听觉预期是不引起注意力分散的主要机制 [9]。

本文主张：在分析音乐的动态组织时，应显式保留转移方向；为此，本文引入 GLMY 路径同调 [10, 11] 与持续路径同调 [12]，比较 Open Focus 与 Classical 两组音乐在局部有向状态转移和跨周期相位闭环上的差异。本研究的目标是得到可计算、可审计并可进一步用于生成控制的拓扑结构表示；进而将其应用到 focus music 的生成中。

本文不评估注意力、学习效果或临床疗效。即使生成音频更接近冻结拓扑指纹，也不能据此推断其对 ADHD 或其他注意力障碍具有治疗作用。

本研究分为两个阶段。第一阶段在 discovery 数据集上拟合并冻结表示，在 validation/180s 上进行主要评估，并以同曲目的 validation/300s 检查时长敏感性；这些步骤形成一个 18 维 Path Homology 指纹。第二阶段提出“精确教师—可微代理—精确复核”的 ACE-Step 1.5 [13] 生成协议。整体分析和应用框架见图 1。该框架不预设 focus music 的任何特征，也不把某个拓扑指标的极大化或极小化视为生成目标，而是试图刻画音乐在局部连通、周期回归之间形成的结构平衡。

本研究的主要贡献总结如下：

- 构建了保留转移方向的多尺度分析框架，通过将音乐状态转换表示为有向图，利用 GLMY 路径同调与持续路径同调分析音乐拓扑特征，并对 Open Focus–Classical 的观察性差异进行评估。
- 提出了相位提升环表示（phase-lifted recurrence graph representation），用跨周期同相位复现定义六相位有向环的边权，并以最弱边的持续阈值刻画闭环强度。
- 按“discovery 拟合与冻结—validation/180s 主要评估—validation/300s 同曲目敏感性检验”组织证据，并冻结由 Pitch、Acoustic phase 与 Chroma phase 构成的 18 维拓扑指纹。
- 提出并训练了潜空间拓扑代理网络（LTSN），学习从 ACE-Step 潜变量到冻结拓扑指纹的可微近似，为采样期潜变量校正提供梯度。




图 1: 整体分析和应用框架。

- 构建了一个来源与逐曲许可可审计的双尺度语料库，包含 300 首 Open Focus 与 300 首 Classical 音乐，每首提供 180s 和 300s 两种分析片段。获取地址 <https://huggingface.co/datasets/fisheryv/open-focus-classical-600>
- 将拓扑特征发现过程中使用的代码封装成了一个 Python 库，名为 pyglmly，可在 <https://github.com/fisheryv/pyglmly> 上获取。

2 Related Work

2.1 音乐拓扑分析

Tonnetz 是音乐几何表示的重要历史来源之一，其后续推广可用于表达音级、音程与时间关系 [14]。Mazzola 的 *The Topos of Music* 则从范畴、模和拓扑等角度建立了更广泛的数学音乐理论框架 [15]。这些工作说明，音乐关系可以被组织为空间或代数结构，但它们并不直接给出本文所需的有向时序统计。

拓扑数据分析 (Topological Data Analysis, TDA) 中的持续同调通过一族过滤复形追踪拓扑特征随尺度的出现与消失 [16]。其中， H_0 描述连通分支， H_1 描述环， H_2 描述二维空腔；持续图 [17] 和 barcode [18] 是同一持续信息的常用摘要形式。在音乐研究中，Sethares 与 Budney 展示了音高、音程和节奏数据中可由拓扑方法揭示的循环结构 [19]；Alcalá-Alvarez 与 Padilla-Longoria 提出了从乐谱点集到单纯复形的系统分析框架 [20]；Heo 等人进一步比较了不同网络距离对音乐持续同调结果的影响 [21]。这些研究共同表明，结果依赖于表示与距离的选择，不能把某一种拓扑摘要视为与表示无关的音乐本质。

然而，标准 Vietoris–Rips 复形具有“无向性”和“对称性”，这种局限使得它无法有效应用于有向图。为了解决有向图的同调计算问题，Alexander Grigor’yan、Yong Lin、Yuri Muranov 和 Shing-Tung Yau 提出路径复形（Path Complex）与路径同调（Path Homology）[10, 11]。Mijangos 等人曾将音程转移表示为图并用持续同调探索音乐风格差异 [22]，Wei 也从拓扑与谱方法研究了乐器声学形状 [23]。相较于 TDA，GLMY 路径同调在功能性音乐中的应用仍较少；本文将工作定位为这一方向的具体实证应用。

2.2 扩散模型生成控制与拓扑约束

目前，潜空间生成控制与拓扑约束还是一个非常前沿的课题。Hu 等人在 3D 形状潜扩散中加入拓扑感知约束 [24]；TopoDDPM 使用持续同调表征辅助点云生成 [25]；TopoLiDM 则通过图神经网络(GNN) 提取拓扑保持的潜图表示来建模 LiDAR 点云 [26]。这些方法说明拓扑摘要可以参与生成条件或损失设计，但研究对象、拓扑构造与评价终点均不同于本文的有向音乐路径同调。

在音乐生成控制方面，Zachary Novack 等人提出了 LatCHs 与 Selective TFG 纯潜空间引导方案 [27]。LatCHs 直接构建在潜扩散模型的中间层扩散特征之上，可以直接在潜空间内预测音乐的动态强度、音高曲线与节拍位置。Selective TFG 技术通过仅在特定选择的少数关键时间步施加 LatCHs 梯度引导，大幅缩短计算耗时。本文与这些工作的联系在于使用可微代理读取潜变量；区别在于代理目标来自冻结的 Path Homology 指纹，并且只有在独立资格检验通过后才允许进入采样器。

3 数据集

3.1 数据来源

本研究使用两组共 600 首独立音乐，源文件总时长为 57.81 小时。所有纳入曲目均记录来源页面、逐曲许可、内容哈希与切分归属。

Open Focus 组：该组由 300 首音乐构成。候选主要来自当前 Jamendo API，标签体系与数据背景参考 MTG-Jamendo [28]；纳入条件包括可核验的 `instrumental` 证据、`focus, meditation` 相关标签、允许下载以及逐曲 Creative Commons 许可。最终清单覆盖 154 位艺术家和 263 张专辑，总时长 29.50 小时。

Classical 组：该组用于提供来源明确的古典器乐比较基线，共计 300 首音乐，来自公共领域标记与学术共享记录：

- 基础池的 95 首音乐来自 Musopen Lossless DVD 项目，来源条目标注为 Public Domain Mark 1.0。涵盖多位大师的钢琴奏鸣曲和弦乐四重奏。
- 扩展池来自 MusicNet Zenodo 记录 [29]，该记录标注为 CC BY 4.0。排除 `source=Musopen` 以及与基础池重复的作品后，按作曲家平衡选取 205 条。

最终 Classical 清单涵盖了从钢琴独奏到室内弦乐的多种编制，总时长为 28.31 小时。

3.2 数据切分与治理

数据治理旨在降低来源、流派、艺人风格或混音技术等带来的混淆因素。每首曲目生成 180s 与 300s 两个尺度：180s 是主要分析尺度，300s 仅用于同曲目时长敏感性。切片优先取曲目中段；短于目标时长时保留整曲，不循环、不补零、不跨曲拼接。

切分在源曲目级完成一次，并应用于两个时长版本。每组均为 discovery 195 首、validation 60 首、holdout 45 首。Open Focus 按艺术家整组划分；Classical 按作曲家并结合重复作品检查进行划分，以避免同一创作者或同一作品跨集合。discovery 用于拟合变换与状态模型，validation/180s 用于主要评估，validation/300s 是同曲目敏感性；当前 holdout 只承担冻结流程与方向的操作性检查，不应视为独立外部验证。

表 1: 数据集构成与分析角色

组别	曲目数	总时长(h)	discovery	validation	holdout	许可	角色
Open Focus	300	29.50	195	60	45	CC	功能性参考
Classical	300	28.31	195	60	45	PDM/CC BY	比较基线
合计	600	57.81	390	120	90		源曲目级分组切分

3.3 数据预处理

在进入拓扑分析前，所有音乐片段经过固定的数字信号处理流程，以减小格式、声道和响度尺度差异。

音频统一解码为 22.05 kHz、单声道、float32 WAV。响度处理采用 Two-pass EBU R128 loudnorm，目标为 -15 LUFS，并在最终采样率下施加 -1 dBFS 峰值上限。当前两组共 1,200 个片段（600 个 180s、600 个 300s）全部通过配置哈希、输出哈希、响度和峰值审计；最终响度范围为 -15.1997 至 -14.8035 LUFS，最大样本峰值为 0.888737。

切片不按最大能量择优，以避免系统性偏向高能量内容。固定候选顺序为中心窗、左侧相邻窗、右侧相邻窗、起始窗和末端窗；只有当前候选触发静音条件时才依次回退，以保证每个切片均包含连续且有效的声学几何信息。

4 拓扑特征发现与验证

4.1 理论基础

本文将音乐视为一个随时间演化的动态系统。音乐的每一小段可以被表示为一个状态，整首音乐则可以表示为状态序列：

$$S = (s_1, s_2, \dots, s_T), \quad s_t \in \mathbb{R}^d.$$

如果音乐状态从 s_t 演化到 s_{t+1} ，则可以构建一个有向转移关系。定义 $i \rightarrow j$ 的非自转移计数为：

$$N_{ij} = \sum_{t=1}^{T-1} \mathbf{1}(s_t = i, s_{t+1} = j, i \neq j),$$

状态 i 的非自转移总数为：

$$N_i^{\text{out}} = \sum_{k \neq i} N_{ik}.$$

则 $i \rightarrow j$ 的边权重为非自转移条件概率，即离开状态 i 的条件下，下一状态为 j 的经验概率：

$$w_{ij} = \frac{N_{ij}}{N_i^{\text{out}}} = \frac{N_{ij}}{\sum_{k \neq i} N_{ik}}, \quad N_i^{\text{out}} > 0.$$

自转移仅用于描述统计，不进入 Path Homology 图；每个源状态只保留权重最高的 6 条出边。

经过状态离散化后，音乐片段可以表示为加权有向图：

$$G_X = (V, E, W).$$

其中 V 是音乐状态集合， E 是状态转移边， W 是边权矩阵。

过滤图 G_τ 保留 $w_{ij} \geq \tau$ 的边；阈值从 0.95 降至 0.05 过程中边逐渐增加：

$$G_\tau = (V, \{i \rightarrow j : w_{ij} \geq \tau\}), \quad G_{0.95} \subseteq G_{0.90} \subseteq \cdots \subseteq G_{0.05}.$$

对允许的 p -路径 $e_{v_0 \dots v_p}$ ，GLMY 边界算子为：

$$\partial e_{v_0 \dots v_p} = \sum_i (-1)^i e_{v_0 \dots \widehat{v_i} \dots v_p},$$

令允许路径空间 $\Omega_p = \{a \in A_p : \partial a \in A_{p-1}\}$ ，则

$$H_p^{\text{path}}(G) = \frac{\ker(\partial_p|_{\Omega_p})}{\text{im}(\partial_{p+1}|_{\Omega_{p+1}})}, \quad \beta_p = \dim H_p^{\text{path}}(G).$$

持久图和 barcode 使用 $a = 1 - \tau$ 把降阈值过滤改写为递增参数。对 $a_i \leq a_j$ ，持久秩不变量为

$$\rho_p(a_i, a_j) = \text{rank im} [H_p(G_{a_i}) \longrightarrow H_p(G_{a_j})].$$

4.2 分析框架与方法

本研究从音高、节奏和调制三个视角将音乐表示为有向图，然后采用 GLMY 路径同调分析，在固定阈值过滤下提取连通性、环结构、持续性、路径熵、复现性及图密度等描述子。三个视角的输入特征和时间分辨率不同，但共享同一分析算子：首先仅在 discovery/180s 上拟合预处理器与状态码本，将连续特征序列 $\mathbf{x}_t^{(v)}$ 量化为离散状态 $s_t^{(v)}$ ；随后由相邻有效状态的转移计数 $N_{ij}^{(v)}$ 构造条件转移概率

$$P_{ij}^{(v)} = \frac{N_{ij}^{(v)}}{\sum_j N_{ij}^{(v)}}.$$

对每个状态保留概率最高的前 6 条非自环出边，并在冻结阈值 $\{0.50, 0.60, 0.70, 0.80, 0.90, 0.95\}$ 上形成超水平过滤。GLMY 路径同调与图统计共同产生 20 个预设指标，覆盖状态占用、转移数量与熵、自转移、有向复现、密度、互惠性以及 H_0/H_1 持续性。自转移比例由原始状态序列统计，不因路径同调图排除自环而丢失。

所有指标在 validation/180s 上进行主验证：每项指标先做两组 Kruskal–Wallis 检验并报告 $\epsilon^2 = (H - k + 1)/(N - k)$ ；预设的 Open Focus–Classical 对比使用双侧 Mann–Whitney U 检验并报告 rank-biserial 效应量。两套结果分别在各视角预定义的 20 指标家族内作 BH-FDR 校正，确认性阈值统一为 $q \leq 0.05$ 。validation/300s 重复同一分析，用于同曲目时长敏感性分析。

4.3 状态表征

音高状态 对每个节拍的 12 维 chroma 向量 c_t 作 L_1 归一化，

$$\tilde{c}_t(k) = \frac{c_t(k)}{\sum_{r=0}^{11} c_t(r) + \varepsilon},$$

再映射到 Harte Tonnetz 的五度、小三度和大三度三个圆周：

$$T(c) = \sum_{k=0}^{11} \tilde{c}(k) \begin{bmatrix} \cos(7\pi k/6) \\ \sin(7\pi k/6) \\ \cos(3\pi k/2) \\ \sin(3\pi k/2) \\ \cos(2\pi k/3) \\ \sin(2\pi k/3) \end{bmatrix}.$$

在 discovery/180s 上按组等量抽取每组 50,000 个有效节拍，拟合固定的 16 状态谐波码本[30]。

节奏状态 固定使用 1s 窗和 0.5s 步长，对第 n 个窗口构造

$$\mathbf{r}_n = [\mu_o, \sigma_o, \max_o, \rho_o, \mu_{IOI}, \sigma_{IOI}, BPM, \rho_b]^\top.$$

其中前四项描述起音包络及起音率， μ_{IOI} 与 σ_{IOI} 描述起音间隔， BPM 和 ρ_b 分别表示局部速度与拍点率。事件不足时相应维度记为缺失，以 discovery 中位数 m_j 填补后按 discovery 均值和标准差标准化：

$$r'_{n,j} = \begin{cases} r_{n,j}, & \text{有效,} \\ m_j, & \text{缺失,} \end{cases} \quad \tilde{r}_{n,j} = \frac{r'_{n,j} - \mu_j}{\sigma_j}.$$

每组等量抽取 50,000 个 discovery 窗口，拟合并冻结 10 状态码本。

调制状态 对 Mel 子带能量包络 $x_b[n]$ 使用 4s 窗和 2s 步长，计算并跨子带累加调制功率：

$$P_t(f_m) = \sum_b \left| \sum_n w[n] x_b[n + tH] e^{-i2\pi f_m n / f_s} \right|^2, \quad \tilde{P}_t(f_m) = \frac{P_t(f_m)}{\sum_{0.5 \leq f \leq 45} P_t(f)}.$$

在 0.5–45Hz 内得到 178 维相对 SMP 后，依次采用 Hellinger 映射、discovery 中位数/IQR 稳健标准化和共享 PCA-32：

$$h_{tj} = \sqrt{\tilde{P}_t(f_j)}, \quad z_{tj} = \frac{h_{tj} - \text{median}_D(h_{\cdot j})}{Q_{0.75,D}(h_{\cdot j}) - Q_{0.25,D}(h_{\cdot j})}, \quad y_t = W_{32}(z_t - \mu_D).$$

32 个主成分累计解释方差为 0.821。平衡抽样后拟合固定的 10 状态码本，并按原始 SMP 频谱质心由低到高排序。

表 2 概括了三个视角的差异。所有缺失值处理、标准化、降维和聚类参数均只由 discovery/180s 估计，随后冻结应用于 validation。

表 2: 局部拓扑三个视角的状态表征

视角	时间单元	连续表征	冻结状态模型
音高	节拍同步	12 维 Chroma $\rightarrow$ 6 维 Tonnetz	MiniBatch K-means, $K = 16$
节奏	1s 窗、0.5s 步长	8 维起音、IOI、BPM 与拍点特征	MiniBatch K-means, $K = 10$
调制	4s 窗、2s 步长	178 维相对 SMP $\rightarrow$ Hellinger $\rightarrow$ PCA-32	MiniBatch K-means, $K = 10$

4.4 验证结果

表 3 汇总主验证与跨时长结果；完整 20 指标统计见附表 9–14。效应量及 180s/300s 稳定性见图 2–7。

表 3: 三个拓扑视角的主要验证结果

视角	180s FDR	跨时长稳定	主要组间方向	H_0	H_1	证据等级
音高	13/20	13	Classical 覆盖与转移更多; Open Focus 状态保持、复现和音高互惠性更高	稳定组间差异	不支持	确认性
节奏	14/20	14	Classical 覆盖、熵、密度和互惠性更高; Open Focus 自转移与复现更高	稳定组间差异	不支持	确认性
调制	5/20	4	Open Focus 状态和绝对边更多, 但密度与互惠性更低	无跨时长稳定结论	不支持	探索性




图 2: 音高 rank-biserial 效应量对比




图 3: 音高跨时长稳定性图




图 4: 节奏 rank-biserial 效应量对比




图 5: 节奏跨时长稳定性图




图 6: 调制 rank-biserial 效应量对比




图 7: 调制跨时长稳定性图

音高和节奏视角呈现共同的组织模式：**Classical** 通常占用更多局部原型、形成更多有向边，并具有更高的路径熵与转移熵；**Open Focus** 则表现出更高的自转移比例和有向复现率。音高视角中，**Classical** 与 **Open Focus** 的状态数中位数分别为 16 对 10、边数为 70 对 31；节奏视角中相应数值分别为 8 对 7、36 对 21。与此同时，**Open Focus** 的音高自转移比例和有向复现率分别为 0.631 和 0.114，高于 **Classical** 的 0.322 和 0.025；节奏视角中的对应数值为 0.662、0.265 与 0.479、0.092。因此，两类音乐的共同差异可概括为 **Classical** 的状态覆盖和转移多样性更广，而 **Open Focus** 的局部状态路径更集中、重复更强。

该共性不能外推到所有连接指标。音高互惠性在 **Open Focus** 中更高（0.667 对 0.522），提示较强的相邻音高双向回返；节奏互惠性则在 **Classical** 中略高（0.809 对 0.769），且其边密度也更高。因此，“**Open Focus** 局部复现更强”仅指自转移和既有有向路径的重复，不能改写为所有视角下的网络都更稠密或更双向。




图 8: 音高视角下 **Classical** 与 **Open Focus** 的主要拓扑特征分布。

调制视角呈现不同于音高和节奏的模式。**Open Focus** 在共享 10 状态 **SMP** 码本中访问更多原型并形成更多绝对边，状态数和边数中位数分别为 6 和 14，高于 **Classical** 的 5 和 11.5；但其边密度和互惠性分别为 0.524 和 0.776，低于 **Classical** 的 0.667 和 0.873。这表明 **Open Focus** 在当前 **SMP** 表征下覆盖更广，但连接相对于潜在边空间更稀疏、双向成对转移更少。四项跨时长稳定指标的 ϵ^2 为 0.051–0.105，rank-biserial 绝对值为 0.279–0.386，故该结果应作为效应有限的探索性解释层，而非已确认的核心指纹。




图 9: 节奏视角下 Classical 与 Open Focus 的主要拓扑特征分布。




图 10: 调制视角下 Classical 与 Open Focus 的主要拓扑特征分布。

三个视角下的 betti 曲线见图 11–13。在同调层级上，音高和节奏的 H_0 结果与状态覆盖差异一致：Classical 在冻结过滤过程中保留更多连通分量并经历更充分的分量合并。不过， H_0 描述子同时受实际占用顶点数影响，应与状态数、边数和熵联合解释，不能单独表述为某一组具有更高或更优的拓扑复杂性。调制视角仅有 `h0_censored_count` 在 180s 通过 FDR，且在 300s 不再显著 ($q = 0.159$)，因而不形成稳定的 H_0 结论。

三个视角均不支持稳定的组间 H_1 差异。主阈值范围内，非零 H_1 片段在音高视角为 Classical 2/60、Open Focus 6/60，在节奏视角均为 1/60，在调制视角为 2/60 和 3/60；六个预设 H_1 指标的组中位数均为 0，且没有指标通过 180s 主分析 FDR。因此，局部视角的主要判别信息来自状态覆盖、转移集中性、局部复现和 H_0 连通过程，而不是稳健的高阶环结构。

4.5 多视角融合与消融分析

音高、节奏和调制视角分别描述和声位置、节奏组织与幅度调制轮廓。为检验这些信息是否互补，本文将三组各 20 个预设拓扑描述子作为独立块进行后融合。整体流程如图 14 所示。

冻结的块归一化与检验设计 直接拼接会使有效维数或协方差尺度较大的视角主导距离。对视角 $v \in \{P, R, M\}$ 的 `discovery/180s` 描述子矩阵，先以 `discovery` 中位数填补缺失值并删除常量列，再估计均值 μ_v 与协方差 Σ_v 。设其有效秩为 r_v ，由 Σ_v 的伪逆诱导白化矩阵 W_v ，定义

$$z_v(x) = \frac{(x - \mu_v)W_v}{\sqrt{r_v}}, \quad W_v W_v^T = \Sigma_v^+.$$




图 11: 音高视角的 Betti 曲线。




图 12: 节奏视角的 Betti 曲线。




图 13: 调制视角的 Betti 曲线。




图 14: 多视角融合分析框架

音高、节奏和调制块的有效秩分别为 13、13 和 14。除以 $\sqrt{r_v}$ 后，各块具有相近的期望平方距离尺度；三视角等权融合与任意两视角组合分别写为

$$z_L(x) = \frac{1}{\sqrt{3}}[z_P(x) \| z_R(x) \| z_M(x)], \quad z_{PR}(x) = \frac{1}{\sqrt{2}}[z_P(x) \| z_R(x)],$$

主要检验为基于欧氏距离的 PERMANOVA，每个表示使用 999 次标签置换。七个单视角或组合表示按时长分别作 BH-FDR 校正。为判断某一视角是否真正增加组间分离几何，在同一标签排列下计算

$$\Delta F = F_{\text{candidate}}^* - F_{\text{baseline}}^*,$$

并对六个“完整融合相对单视角”及“加入一个视角”的比较按时长分别校正；只有 $\Delta F > 0$ 且 $q \leq 0.05$ 才判为正增量。另在 discovery/180s 上用其余两块拟合多输出岭回归 $\hat{f}_v$ ，在 validation 中对残差

$$R_v = Z_v - \hat{f}_v(Z_{-v})$$

再次进行 PERMANOVA，以诊断目标视角是否含有不能由其余两视角预测的组别信息。该条件残差检验不等价于因果分解，也不保证加入该视角后整体距离判别一定提高。

整体分离与组合消融 表 4 显示，七种表示在两个时长下均能区分 Open Focus 与 Classical（原始置换 p 均为 0.001，BH-FDR $q = 0.001$ ）。完整融合在 180s 的 pseudo- F 为 6.27，在 300s 为 10.54；但 180s 最强单视角是音高（ $F^* = 7.59$ ），300s 亦为音高（ $F^* = 18.19$ ）。因此，完整融合显著只能说明融合空间保留了组间差异，不能据此声称它优于最佳单视角。

表 4: 局部三视角融合及组合消融的 PERMANOVA 结果

表示	维数	180s F^*	180s q	300s F^*	300s q
音高 (P)	16	7.59	0.001	18.19	0.001
节奏 (R)	16	6.47	0.001	10.24	0.001
调制 (M)	17	4.13	0.001	4.24	0.001
$P + R$	32	7.08	0.001	14.11	0.001
$P + M$	33	6.17	0.001	10.69	0.001
$R + M$	33	5.40	0.001	7.10	0.001
$P + R + M$	49	6.27	0.001	10.54	0.001

融合空间的二维投影 为直观展示完整融合表示中的样本关系，图 15 使用仅在 discovery/180s 上拟合的 PCA，将 validation/180s 的 49 维融合坐标投影到前两个主成分。Classical 曲目主要分布在 PC1 正向且相对集中，Open Focus 整体偏向 PC1 负向并呈现更大的组内离散，但两组仍存在明显重叠。PC1 与 PC2 分别只解释 4.8% 和 4.7% 的方差，合计为 9.5%；因此该图仅提供低维几何直觉，不参与 PERMANOVA 或配对增量检验。




图 15: 由 discovery/180s 拟合的 PCA 对 validation/180s 三视角融合表示的二维投影。每个点代表一首曲目；椭圆阴影表示以组内均值为中心、沿组内协方差主轴延伸 1.96 个标准差的投影范围，并非 bootstrap 置信区间。

增量与条件非冗余 配对增量结果见图 16。在 180s 主分析中，完整融合相对音高的 $\Delta F = -1.32$ ($q = 1$)，相对节奏为 -0.205 ($q = 1$)；相对调制虽为 2.14 ($q = 0.003$)，但这仅说明融合优于较弱的调制单视角。留一视角消融中，向“节奏+调制”加入音高产生稳定正增量（180s: $\Delta F = 0.864$, $q = 0.003$; 300s: 3.44 , $q = 0.003$ ）。向“音高+调制”加入节奏在 180s 的增量仅为 0.101 ($q = 0.462$)，而向“音高+节奏”加入调制反而为 -0.814 ($q = 1$)；二者均无正向增量证据。该结果将音高识别为当前等权距离中的主要分离块，而不支持“每增加一个视角都会增强组间几何”的假设。

表 5: 局部三视角融合的配对 pseudo- F 增量检验结果

比较	180 s ΔF	180s FDR	300s ΔF	300s FDR
Full-Pitch	-1.32	1	-7.65	1
Full-Rhythm	-0.205	1	0.298	0.342
Full-Modulation	2.14	0.003	6.3	0.003
Add Pitch to Rhythm+Modulation	0.864	0.003	3.44	0.003
Add Rhythm to Pitch+Modulation	0.101	0.462	-0.146	1
Add Modulation to Pitch+Rhythm	-0.814	1	-3.56	1




图 16: 局部三视角融合的对伪 F 增量检验。浅色柱表示未同时满足 $\Delta F > 0$ 与 BH-FDR $q \leq 0.05$; 300s 仅作同曲目时长敏感性。

条件残差给出了不同但互补的问题答案。表 6 中，三个视角的残差在 180s 均仍含显著组别结构；300s 方向也一致。然而，节奏和调制的 validation R^2 接近零或为负，说明 discovery 上拟合的跨视角预测关系并未稳定推广。因而，这些结果支持三视角包含条件非冗余信息，但不能推导为每个视角都对等权融合产生可验证的正增量。

表 6: 各局部视角在条件于其余两视角后的残差 PERMANOVA

目标视角	180s F^*	180s q	validation R^2	300s F^*	300s q
音高	4.53	0.0015	0.0476	11.74	0.0015
节奏	3.39	0.0015	-0.0089	6.34	0.0015
调制	2.22	0.0100	0.0034	1.88	0.0310

辅助分类及指标分歧 作为辅助分析，在 discovery/180s 内部以五折交叉验证选择 C 的 L2 logistic regression，冻结后应用于 validation；分类差异使用固定种子的 1,000 次组内分层 bootstrap。完整融合在 180s 的 balanced accuracy、Macro-F1 和 AUROC 分别为 0.967、0.967 和 0.991，音高单视角分别为 0.925、0.925 和 0.986。完整融合相对音高的 balanced accuracy 增量为 0.0417，bootstrap 95% CI 为 [0.0165, 0.0750]。此外，在 $P + R$ 上加入调制后 balanced accuracy 增加 0.0333，95% CI 为 [0.0083, 0.0667]；但其距离增量为 $\Delta F = -0.814$ 、 $q = 1$ 。分类性能衡量逐曲判别，pseudo- F 衡量组间距离相对组内离散的比例，两者可以不同方向变化，因此必须并列报告，不能只选择有利指标。

综合判断与证据边界 局部三视角等权融合保留了稳定的组间可分性，并在辅助逐曲分类上优于音高单视角；但它没有提高相对最佳单视角的 pseudo- F ，且留一视角检验只确认了音高的正向几何增量。节奏和调制具有条件非冗余与独立解释价值，却尚无证据表明它们在当前等权距离中提供稳定




图 17: 由 discovery/180s 冻结的辅助分类消融结果。分类结果用于补充距离几何检验，不替代 PER-MANOVA 或配对增量检验。

的增量分离。因此，本文将音高视为局部指纹的主要分离块，将节奏与调制保留为互补解释块，而不宣称三视角融合在整体上优于最佳单视角。

4.6 拓扑指纹冻结

根据前述单指标验证、多尺度稳定性与融合增量分析，本文将 Focus Music 的拓扑指纹冻结为三维 Pitch Path Homology 表示，记为

$$\Phi_{\text{PH}}(x) = [z_{H_0}(x), z_{\text{self}}(x), z_{\text{rec}}(x)] \in \mathbb{R}^3. \quad (1)$$

该指纹只保留局部 Pitch 分支，因为跨周期相位及其与 Pitch 的联合表示均未稳定优于最佳 Pitch 单块，而 Pitch 是局部融合中唯一具有稳定正向几何增量的视角。三个坐标分别描述局部连通与状态覆盖、局部稳定与停留以及有向重复结构，在统计支持、跨时长稳定性和结构含义之间形成互补。

表 7: Focus Music 三维拓扑指纹的冻结组成与验证依据

原始指标	结构含义	Focus 方向	180s BH-FDR q	180/300s ρ
h0_observed_persistence	局部连通与状态覆盖	较低	8.94×10^{-19}	0.953
self_transition_ratio	局部稳定与停留	较高	3.97×10^{-16}	0.979
directed_recurrence	有向重复结构	较高	1.16×10^{-16}	0.983

与直接采用 vertex_count 和 edge_count 相比，当前组合避免两个图规模计数特征重复表达相近信息，并保留了状态覆盖、停留和有向复现三种不同机制。三项指标均在预设 Pitch 检验族中通过 validation/180s 的 BH-FDR，并在同曲 validation/300s 保持方向和较高配对 Spearman 相关。三维辅助逻辑回归在 validation/180s 的 balanced accuracy 为 0.942、AUROC 为 0.980，在 300s 敏感性分析中的对应值为 0.942 和 0.988；这些结果表明该低维表示保留了主要组间判别信息，但不等于生成可控性或注意力改善证据。

除表 7 的指标顺序外，以下字段一并冻结：

1. 状态码本与三个原始描述子沿用 Pitch 分支的既有定义；标准化只使用 discovery/180s，中心取中位数，尺度优先取归一化 IQR，并以归一化 MAD 和标准差依次回退；
2. 坐标顺序固定为 H_0 observed persistence、self-transition ratio、directed recurrence，三维距离及带外损失权重均为 1/3；
3. Focus 目标带只由 discovery/180s Focus 样本各坐标的第 10–90 百分位数确定；具体中心、尺度和目标带见表 8；
4. validation/180s 用于主要验证，validation/300s 仅作同曲时长敏感性；已开启 holdout 不用于变换拟合、目标带设定、权重或阈值调整；
5. 指纹 JSON、逐曲分数、配置、代码和来源表均以 SHA-256 绑定。任何特征替换、顺序变化、重新加权或目标带修改都必须建立新版本。

该三维对象是本文后续精确教师、代理训练和生成控制共同使用的唯一冻结拓扑指纹。冻结后，不允许替换指标、改变坐标顺序、重新加权或根据生成结果修改目标带；任何此类变化都必须建立新的指纹版本并重新完成验证。该指纹是可审计的结构表示，不是注意力、疗效或音乐质量的因果量表，也不凭自身授权采样期校正；只有代理通过独立资格检验后，corrector 才能由关闭状态转为候选启用。

5 ACE-Step 拓扑引导音乐生成

5.1 研究边界与方法概览

本文进一步考察如何在不重新训练基础生成模型的前提下，将局部 Pitch Path Homology 用作 ACE-Step 1.5 XL-Turbo 的推理期控制信号[13]。与直接在波形域计算控制损失并反向传播穿过 VAE 解码器的方法相比，潜空间控制头可以显著降低单次梯度计算的显存和时间开销；Novack 等人提出的 Latent-Control Head (LatCH) 与 selective TFG 已验证了这种“潜变量到控制量”路线的可行性[27]。本文沿用其低资源思想，但控制对象不是逐帧强度、音高类别或节拍曲线，而是整段音乐的三个全局局部拓扑坐标。

方法仍遵循“精确教师–可微代理–精确复核”闭环：精确 Pitch PH 从每个独立解码的轨迹快照生成三维标签；轻量潜空间拓扑控制头 (Latent Topology Control Head for Pitch-3, LTCH-P3) 学习从预测干净潜变量到该标签的可微映射；只有在未见 prompt、seed family 与生成轨迹上通过预测、校准、OOD 和解码后方向一致性门槛，代理梯度才允许在少数采样步骤中启用。最终音频仍由精确教师、音质指标与 prompt 一致性共同裁决。

5.2 三维精确拓扑教师

令 $f(x) \in \mathbb{R}^3$ 表示从音频 x 的完整 Pitch 图描述子中选出的三个互补指标：

$$f(x) = [f_{H_0}(x), f_{\text{self}}(x), f_{\text{rec}}(x)], \quad (2)$$

其中 f_{H_0} 为 h0_observed_persistence，刻画局部连通与状态覆盖； f_{self} 为 self_transition_ratio，刻画局部停留； f_{rec} 为 directed_recurrence，刻画有向重复。三项均在 validation/180s 通过原预设 Pitch 检验族的 BH-FDR，并在同曲 validation/300s 中保持方向和较高配对相关；选择规则强调统计支持、跨时长稳定和机制互补，而不是简单截取旧白化坐标。

所有变换只使用 discovery/180s 拟合。设第 j 项的 discovery 中位数为 m_j ，稳健尺度为 s_j ，则冻结坐标为

$$z_j(x) = \frac{f_j(x) - m_j}{s_j}, \quad z(x) = [z_{H_0}, z_{\text{self}}, z_{\text{rec}}] \in \mathbb{R}^3. \quad (3)$$

冻结参数和 discovery Focus 的目标带列于表 8。

表 8: Pitch-3 精确教师的冻结标准化与目标带

坐标	中心 m_j	尺度 s_j	Focus 目标带 $[l_j, u_j]$
H_0 observed persistence	4.2000	2.3629	$[-1.265, -0.042]$
self-transition ratio	0.4600	0.2800	$[0.041, 1.184]$
directed recurrence	0.05685	0.08077	$[0.117, 3.133]$

目标带由 discovery Focus 各坐标的第 10–90 百分位数确定。三个坐标等权，精确带外损失定义为

$$L_{\text{band}}(z) = \frac{1}{3} \sum_{j=1}^3 \{ [\max(l_j - z_j, 0)]^2 + [\max(z_j - u_j, 0)]^2 \}. \quad (4)$$

样本进入经验支持区间后，该坐标的梯度归零，因而控制目标是回到 Focus 参考分布邻域，而不是无限降低 H_0 或无限提高重复率。另在 discovery/180s 上冻结三维 L2 逻辑回归

$$S_F(x) = w^\top z(x) + b, \quad (5)$$

作为联合方向的辅助读出；由于三个坐标仍有相关性， S_F 不作为唯一引导能量，避免模型利用线性分类边界中的相关性捷径。

5.3 预测干净潜变量与时间条件

ACE-Step XL-Turbo 的声学潜变量记为 $x_t \in \mathbb{R}^{B \times T \times 64}$ 。LTCH-P3 不只读取最终潜变量，而读取每个被标注采样步自身的预测干净潜变量。对当前 flow-matching 参数化，定义

$$\hat{x}_{0|t} = x_t - tv_t, \quad (6)$$

其中 v_t 是基础模型在噪声时间 t 的速度预测。连续时间 t 与离散 step id 分别作多频 Fourier 编码，再经两层 MLP 得到 128 维条件向量

$$e_t = \text{MLP}(\text{Fourier}(t, \text{step})) \in \mathbb{R}^{128}. \quad (7)$$

该条件向量被投影为通道尺度和偏移，对时序特征执行

$$h'_i = h_i \odot [1 + \gamma(e_t)] + \beta(e_t), \quad (8)$$

使网络能够区分同一潜结构在不同去噪阶段上的可信度。

5.4 LTCH-P3 网络结构

LTCH-P3 是面向整段 180 秒音频的全局控制头，不输出逐帧控制曲线。其计算流程见图 18。

首先对输入逐帧执行 LayerNorm 和 $64 \rightarrow 128$ 线性投影。随后使用 depthwise Conv1d (kernel 9、stride 4、padding 4) 将长度从 T 降到约 $\lceil T/4 \rceil$ ；卷积只作逐通道时间聚合，通道混合由前置线性层完成。相对于直接在全长序列上自注意力，该操作将注意力矩阵的渐近开销降至约原来的 $1/16$ 。




图 18: LTCH-P3 的全局三维潜空间拓扑代理结构。

下采样序列加入正弦绝对位置编码，并经三个 pre-norm Transformer encoder block。每层使用 $d_{\text{model}} = 128$ 、4 个注意力头、FFN 宽度 512、GELU 和 dropout 0.1。本文未直接复制 LatCH 的 RoPE，而保留更简单的固定位置编码；该选择应在真实长序列训练后再决定是否需要位置编码消融。

Transformer 输出经掩码 attention pooling、均值 pooling 和标准差 pooling，得到 $128 \times 3 = 384$ 维全局统计；与 128 维时间条件拼接为 512 维，经 $512 \rightarrow 256 \rightarrow 128$ 的 SiLU MLP 得到共享表征。按当前层配置计算，模型约含 0.87M 个可训练参数，低于 Novack 等人约 7M 参数的 LatCH 规模[27]。这种压缩主要来自三维全局目标，而非时间对齐的高维控制序列。

输出包括三维坐标均值、三维对数方差和一个 OOD logit:

$$g_\phi(\hat{x}_{0|t}, t) = (\hat{\mu}_z, \log \hat{\sigma}_z^2, u_{\text{OOD}}). \quad (9)$$

对数方差限制在 $[-8, 4]$ 。冻结 Focus logit 不设置独立自由分类头，而由

$$\hat{S}_F = w^\top \hat{\mu}_z + b \quad (10)$$

确定性计算，从而保证联合读出与预测坐标一致。对数方差表示单模型 aleatoric uncertainty；其校准和 OOD 阈值必须在独立 calibration 分区完成，当前不能直接解释为有效置信区间。

5.5 教师标签、数据构造与防泄漏

每个训练样本为 $(\hat{x}_{0|t}, t, z, S_F, y_{\text{OOD}})$ 。在无引导生成轨迹中保存第 4、5、6 步及最终步的 (x_t, v_t, t) ，按式 (6) 构造各自的 $\hat{x}_{0|t}$ ，分别经 VAE 解码，再独立运行 exact Pitch PH。不得把最终音频标签复制到中间步骤，否则网络会学习错误的时间不变映射。

正式 prompt 清单包含 512 个变体，按 prompt family 固定为 train/development/calibration/qualification 的 320/64/64/64 划分；每个 prompt 计划生成 4 个确定性 seed，共 2048 条轨迹和最多 8192 个常规快照。安全/OOD 样本包括静音、削波、极低动态、机械短循环、过度平滑和异常潜变量，但不得通过改变资格门槛来迁就 OOD 失败。

数据清单强制校验指纹 SHA-256、三维坐标顺序、latent SHA-256 和逐快照标签来源。同一 prompt、同一 prompt family、同一轨迹及其全部 seed/快照必须位于同一分区。论文的 validation 与已开启 holdout 只承担拓扑证据和历史兼容性说明，不用于 LTCH-P3 的架构选择、损失调权、early stopping 或阈值校准。

5.6 损失函数与训练配置

只有 ID 样本参与坐标、异方差和 Focus 读出回归，全部样本参与 OOD 分类。坐标损失为

$$L_{\text{coord}} = \frac{1}{3} \sum_{j=1}^3 \text{SmoothL1}(\hat{\mu}_j - z_j). \quad (11)$$

令 $s_j = \log \hat{\sigma}_j^2$ ，异方差负对数似然为

$$L_{\text{NLL}} = \frac{1}{6} \sum_{j=1}^3 [e^{-s_j} (\hat{\mu}_j - z_j)^2 + s_j]. \quad (12)$$

辅助读出损失为 $L_{\text{Focus}} = \text{SmoothL1}(\hat{S}_F - S_F)$ ，安全损失为带类别权重的 $L_{\text{OOD}} = \text{BCEWithLogits}(u_{\text{OOD}}, y_{\text{OOD}})$ 。当前代码合同冻结总损失

$$L = L_{\text{coord}} + 0.25L_{\text{NLL}} + 0.25L_{\text{Focus}} + 0.1L_{\text{OOD}}. \quad (13)$$

训练使用 AdamW，初始学习率 2×10^{-4} 、weight decay 10^{-4} 、micro-batch size 8、最大 40 epochs；至少训练 8 epochs 后，若 development 总损失连续 7 epochs 无改善则 early stop；全局梯度范数裁剪为 1.0。支持 bf16 前向，但损失和检查点统计保持 fp32。训练阶段只读取预计算 latent 与精确标签，不加载 ACE-Step DiT 或 VAE。每个 checkpoint 原子写入并绑定指纹、训练配置与数据清单哈希，且默认写入 guidance_promotion_eligible=false 和 production_authorization=false。

5.7 选择性采样校正与安全回退

通过资格检验后，LTCH-P3 可作为 selective latent guidance 的控制头。在选定采样步，将基础模型计算从梯度图中分离，只对预测干净潜变量开启梯度：

$$\tilde{x}_{0|t} = \text{stopgrad}(x_t - tv_t), \quad \tilde{x}_{0|t}.\text{requires_grad} = \text{True}. \quad (14)$$

代理能量采用式 (4) 在预测均值上的版本：

$$\hat{\mathcal{E}}_t = L_{\text{band}}(\hat{\mu}_z(\tilde{x}_{0|t}, t)), \quad g_t = \nabla_{\tilde{x}_{0|t}} \hat{\mathcal{E}}_t. \quad (15)$$

若 OOD 概率、预测方差、NaN/Inf、哈希不一致或掩码检查任一超阈，则该样本必须 no-op。有效梯度经时间低通和相对 RMS clip 后，才可映射到下一潜变量状态。初始设计仍只考察第 4–6 步，避免高噪声早期和直接输出端；步间权重与 RMS 半径只能在 development 上从预设候选中选择一次。

需要强调的是，当前仓库已经实现三维精确教师、LTCH-P3、哈希标签清单和训练入口，但尚未实现并授权新的采样器 corrector。上述更新式是待资格检验的推理协议，不是已取得的生成结果。

5.8 资格检验、最终评价与当前状态

LTCH-P3 只有在未见 prompt、seed family 和轨迹上同时满足以下条件，才允许进入采样器：Focus logit Spearman $\rho \geq 0.70$ ；三个坐标各自及其中位数 Spearman 均不低于 0.50；三维目标带距离 Spearman 不低于 0.50；exact 高/低四分位排序准确率不低于 0.65；90% 预测区间覆盖率位于 0.85–0.95；校正步骤的 ID 接受率不低于 0.95；OOD AUROC 与 sensitivity 均不低于 0.80；代理优化后解码音频的 exact 改善方向一致率不低于 0.65。任一坐标、OOD 或解码后方向门槛失败，都不能由总体 Focus logit 掩盖。

最终确认实验继续采用未参与开发的 32 个 prompts、每个 prompt 8 个 seeds，形成 256 对 baseline/guided 配对和 512 首 180 秒音频。主要终点为

$$\Delta_i = L_{\text{band}}^{\text{guided}}(i) - L_{\text{band}}^{\text{base}}(i), \quad (16)$$

其中负值表示更接近冻结三维目标带。报告中位差、Hodges–Lehmann 位移、按 prompt 聚类的 bootstrap 95% 置信区间及目标带命中率；同时执行 prompt 一致性、响度、true peak、削波、静音、频谱

异常、机械短循环、过度平滑、多样性、运行时间和显存的预设非劣检验。若能完成合规审批，再把盲听作为补充终点，而不以主观结果替代精确拓扑和技术质量门槛。

当前证据状态：三维指纹已由 discovery/180s 稳健变换冻结，并在现有 1200 个 180/300 秒片段上完成确定性数值重建；代理网络、训练器和标签清单已通过本地静态及非 Torch 测试。由于本机没有 PyTorch/CUDA，真实 ACE-Step 轨迹收集、LTCH-P3 训练、OOD 校准、解码后方向一致性和最终 baseline/guided 评价均尚未执行。因此，本节只报告已实现的方法与预设门槛，采样期 corrector 继续保持关闭。

References

- [1] S. Prasad and R. Kumminimana, "Attention-deficit/hyperactivity disorder: insights, advances and challenges in research and practice," *Postep Psychiatr Neurol*, vol. 34, no. 3, pp. 196–206, 2025. [Online]. Available: <https://doi.org/10.5114/ppn.2025.153717>
- [2] N. Madjar, R. Gazoli, I. Manor, and G. Shoval, "Contrasting effects of music on reading comprehension in preadolescents with and without adhd," *Psychiatry Research*, vol. 291, p. 113207, 2020. [Online]. Available: <https://doi.org/10.1016/j.psychres.2020.113207>
- [3] P. Saville, C. Kinney, A. Heiderscheit, and H. Himmerich, "Exploring the intersection of adhd and music: A systematic review," *Behavioral Sciences*, vol. 15, no. 1, p. 65, 2025. [Online]. Available: <https://doi.org/10.3390/bs15010065>
- [4] I. Erarslan, M. Budak, and D. Tarakci, "Effects of music-based occupational therapy activities on attention executive functions in children with attention deficit and hyperactivity disorder," *PLOS ONE*, vol. 21, no. 5, pp. 1–11, May 2026. [Online]. Available: <https://doi.org/10.1371/journal.pone.0349284>
- [5] K. J. P. Woods, G. Sampaio, T. James, E. Przysinda, B. Cordovez, A. Hewett, A. E. Spencer, B. Morillon, and P. Loui, "Rapid modulation in music supports attention in listeners with attentional difficulties," *Communications Biology*, vol. 7, no. 1, p. 1376, 2024. [Online]. Available: <https://doi.org/10.1038/s42003-024-07026-3>
- [6] K. Achuthan and S. Khobragade, "The role of music in adhd: A multi-dimensional computational and theoretical analysis," *PLOS ONE*, vol. 20, no. 8, p. e0324369, 2025. [Online]. Available: <https://doi.org/10.1371/journal.pone.0324369>
- [7] S. Koelsch, T. Gunter, A. D. Friederici, and E. Schröger, "Brain indices of music processing: "nonmusicians" are musical," *Journal of cognitive neuroscience*, vol. 12, no. 3, pp. 520–541, 2000. [Online]. Available: <https://doi.org/10.1162/089892900562183>
- [8] D. Huron, "Tone and voice: A derivation of the rules of voice-leading from perceptual principles," *Music Perception*, vol. 19, pp. 1–64, 09 2001. [Online]. Available: <https://doi.org/10.1525/mp.2001.19.1.1>
- [9] L. Fiedler, I. Johnsrude, and D. Wendt, "Salience-dependent disruption of sustained auditory attention can be inferred from evoked pupil responses and neural tracking of task-irrelevant sounds," *Journal of Neuroscience*, vol. 45, no. 14, 2025. [Online]. Available: <https://www.jneurosci.org/content/45/14/e2066232025>
- [10] A. Grigor'yan, Y. Lin, Y. Muranov, and S.-T. Yau, "Homologies of path complexes and digraphs," 2013. [Online]. Available: <https://arxiv.org/abs/1207.2834>
- [11] A. Grigor'yan, Y. Lin, Y. V. Muranov, and S.-T. Yau, "Path complexes and their homologies," *Journal of Mathematical Sciences*, vol. 248, pp. 564–599, 2020. [Online]. Available: <https://link.springer.com/article/10.1007/s10958-020-04897-9>
- [12] S. Chowdhury and F. Mémoli, "Persistent path homology of directed networks," 2017. [Online]. Available: <https://arxiv.org/abs/1701.00565>

- [13] J. Gong, Y. Song, W. Zhao, S. Wang, S. Xu, J. Guo, and X. Yang, “Ace-step 1.5: Pushing the boundaries of open-source music generation,” 2026. [Online]. Available: <https://arxiv.org/abs/2602.00744>
- [14] J. Yust, “Generalizedtonnetzeandzeitnetze, and the topology of music concepts,” *Journal of Mathematics and Music*, vol. 14, pp. 170–203, Mar 2020. [Online]. Available: <https://doi.org/10.1080/17459737.2020.1725667>
- [15] G. Mazzola, *The Topos of Music*. Springer Cham, 2017.
- [16] Edelsbrunner, Letscher, and Zomorodian, “Topological persistence and simplification,” *Discrete and Computational Geometry*, vol. 28, pp. 511–533, 2002. [Online]. Available: <https://doi.org/10.1007/s00454-002-2885-2>
- [17] D. Cohen-Steiner, H. Edelsbrunner, and J. Harer, “Stability of persistence diagrams,” *Discrete and Computational Geometry*, vol. 37, pp. 103–120, 2007. [Online]. Available: <https://doi.org/10.1007/s00454-006-1276-5>
- [18] G. E. Carlsson, A. Zomorodian, A. D. Collins, and L. J. Guibas, “Persistence barcodes for shapes,” *Int. J. Shape Model.*, vol. 11, pp. 149–188, 2004. [Online]. Available: <https://api.semanticscholar.org/CorpusID:456712>
- [19] W. A. Sethares and R. Budney, “Topology of musical data,” *Journal of Mathematics and Music*, vol. 8, no. 1, pp. 73–92, Jan 2014. [Online]. Available: <http://dx.doi.org/10.1080/17459737.2013.850597>
- [20] A. Alcalá-Alvarez and P. Padilla-Longoria, “A framework for topological music analysis (tma),” *Journal of Mathematics and Music*, vol. 18, no. 1, pp. 139–172, 2024. [Online]. Available: <https://doi.org/10.1080/17459737.2023.2219994>
- [21] E. Heo, B. Choi, M. O. Kim, M. L. Tran, and J.-H. Jung, “Persistent homology of music network with three different distances,” *Journal of Mathematics and Music*, vol. 20, no. 2, pp. 154–186, Nov 2025. [Online]. Available: <http://dx.doi.org/10.1080/17459737.2025.2568844>
- [22] M. Mijangos, A. Bravetti, and P. Padilla, “Musical stylistic analysis: A study of intervallic transition graphs via persistent homology,” 2022. [Online]. Available: <https://arxiv.org/abs/2204.11139>
- [23] G.-W. Wei, “Topological data analysis hearing the shapes of drums and bells,” 2023. [Online]. Available: <https://arxiv.org/abs/2301.05025>
- [24] J. Hu, B. Fei, B. Xu, F. Hou, W. Yang, S. Wang, N. Lei, C. Qian, and Y. He, “Topology-aware latent diffusion for 3d shape generation,” 2024. [Online]. Available: <https://arxiv.org/abs/2401.17603>
- [25] S. Du, Z. Guan, and Q. Liu, “Topoddpm: Diffusion probabilistic model using persistent homology for 3d point cloud generation,” *Neural Networks*, vol. 204, p. 109240, 2026. [Online]. Available: <https://doi.org/10.1016/j.neunet.2026.109240>
- [26] J. Liu, Z. Huang, M. Liu, T. Deng, F. Nex, H. Cheng, and H. Wang, “Topolidm: Topology-aware lidar diffusion models for interpretable and realistic lidar point cloud generation,” 2025. [Online]. Available: <https://arxiv.org/abs/2507.22454>

- [27] Z. Novack, Z. Zukowski, C. Carr, J. Parker, Z. Evans, J. Taylor, T. Berg-Kirkpatrick, J. McAuley, and J. Pons, “Low-resource guidance for controllable latent audio diffusion,” 2026. [Online]. Available: <https://arxiv.org/abs/2603.04366>
- [28] D. Bogdanov, M. Won, P. Tovstogan, A. Porter, and X. Serra, “The mtg-jamendo dataset for automatic music tagging,” in *Machine Learning for Music Discovery Workshop, International Conference on Machine Learning (ICML 2019)*, Long Beach, CA, United States, 2019. [Online]. Available: <http://hdl.handle.net/10230/42015>
- [29] J. Thickstun, Z. Harchaoui, and S. M. Kakade, “Musicnet,” Nov. 2016. [Online]. Available: <https://doi.org/10.5281/zenodo.5120004>
- [30] C. Harte, M. Sandler, and M. Gasser, “Detecting harmonic change in musical audio,” in *Proceedings of the 1st ACM Workshop on Audio and Music Computing Multimedia*, ser. AMCMM ’06. New York, NY, USA: Association for Computing Machinery, 2006, pp. 21–26. [Online]. Available: <https://doi.org/10.1145/1178723.1178727>

A 完整特征指标数据

本附录提供音高、节奏、调制视角下古典音乐与专注音乐的完整拓扑特征对比数据。各指标按 180s 主分析的 ϵ^2 降序排列；其中 ϵ^2 为 Kruskal-Wallis 秩效应量，BH-FDR q 为在预设检验族内对原始 p 值进行 Benjamini-Hochberg 校正后的 p 值。独立两两比较另行报告 rank-biserial 效应量。

A.1 音高视角

表 9: 音高视角下古典音乐与专注音乐的拓扑特征对比

指标	Median _{Classical}	Median _{Focus}	ϵ^2	180s BH-FDR q	300s BH-FDR q
vertex_count	16.000	10.000	0.703	8.2e-19	2.8e-19
edge_count	70.000	31.000	0.683	8.2e-19	1.8e-19
h0_betti_auc	6.200	3.125	0.677	8.2e-19	1.8e-19
h0_betti_mean	13.667	6.833	0.676	8.2e-19	1.8e-19
h0_observed_persistence	6.375	3.325	0.677	8.2e-19	1.8e-19
h0_betti_max	14.500	8.000	0.672	8.2e-19	1.8e-19
h0_interval_count	14.500	8.000	0.672	8.2e-19	1.8e-19
path_entropy	1.696	0.965	0.673	8.2e-19	1.8e-19
h0_censored_count	11.000	3.500	0.596	6.53e-17	7.59e-18
directed_recurrence	0.025	0.114	0.585	1.14e-16	4.43e-17
self_transition_ratio	0.322	0.631	0.563	3.89e-16	1.92e-16
transition_entropy	0.915	0.771	0.489	3.03e-14	8.01e-14
reciprocity	0.522	0.667	0.361	6.25e-11	2.31e-09
edge_density	0.311	0.332	0.025	0.0654	1
h1_betti_auc	0.000	0.000	0.010	0.153	0.0255
h1_betti_max	0.000	0.000	0.010	0.153	0.0255
h1_betti_mean	0.000	0.000	0.010	0.153	0.0255
h1_censored_count	0.000	0.000	0.010	0.153	0.0255
h1_interval_count	0.000	0.000	0.010	0.153	0.0255
h1_observed_persistence	0.000	0.000	0.000	1	1

表 10: 音高视角在主尺度通过独立两两 FDR 的指标（Open Focus-Classical）

指标	rank-biserial	BH-FDR q	指标	rank-biserial	BH-FDR q
edge_count	-0.956	8.4e-19	vertex_count	-0.954	8.4e-19
h0_betti_auc	-0.952	8.4e-19	h0_censored_count	-0.892	6.68e-17
h0_betti_max	-0.944	8.4e-19	directed_recurrence	0.886	1.16e-16
h0_betti_mean	-0.951	8.4e-19	self_transition_ratio	0.869	3.97e-16
h0_interval_count	-0.944	8.4e-19	transition_entropy	-0.811	3.09e-14
h0_observed_persistence	-0.952	8.4e-19	reciprocity	0.699	6.37e-11
path_entropy	-0.949	8.4e-19			

A.2 节奏视角

表 11: 节奏视角下古典音乐与专注音乐的拓扑特征对比

指标	Median _{Classical}	Median _{Focus}	ϵ^2	180s BH-FDR q	300s BH-FDR q
path_entropy	1.336	0.866	0.390	1.38e-10	1.06e-10
edge_count	36.000	21.000	0.356	5.48e-10	3.06e-10
directed_recurrence	0.092	0.265	0.311	5.47e-09	1.78e-08
h0_betti_mean	6.833	4.750	0.299	8.56e-09	4.62e-09
h0_betti_auc	3.100	2.175	0.288	1.35e-08	4.62e-09
h0_observed_persistence	3.300	2.275	0.276	2.02e-08	4.62e-09
transition_entropy	0.792	0.611	0.276	2.02e-08	4.82e-07
h0_betti_max	8.000	6.000	0.256	5.13e-08	2.50e-08
h0_interval_count	8.000	6.000	0.256	5.13e-08	2.50e-08
self_transition_ratio	0.479	0.662	0.252	5.78e-08	3.15e-08
h0_censored_count	5.000	2.000	0.245	8.46e-08	1.24e-05
vertex_count	8.000	7.000	0.166	9.64e-06	1.83e-05
edge_density	0.577	0.493	0.075	0.00267	1.84e-05
reciprocity	0.809	0.769	0.039	0.0248	0.00639
h1_observed_persistence	0.000	0.000	0.000	0.423	1
h1_betti_auc	0.000	0.000	0.000	1	0.334
h1_betti_max	0.000	0.000	0.000	1	0.334
h1_betti_mean	0.000	0.000	0.000	1	0.334
h1_censored_count	0.000	0.000	0.000	1	0.334
h1_interval_count	0.000	0.000	0.000	1	0.334

表 12: 节奏视角在主尺度通过独立两两 (Open Focus-Classical) FDR 的指标

指标	rank-biserial	BH-FDR q	指标	rank-biserial	BH-FDR q
path_entropy	-0.726	1.4e-10	h0_betti_max	-0.580	5.21e-08
edge_count	-0.694	5.58e-10	h0_interval_count	-0.580	5.21e-08
directed_recurrence	0.650	5.56e-09	self_transition_ratio	0.587	5.86e-08
h0_betti_mean	-0.637	8.7e-09	h0_censored_count	-0.570	8.59e-08
h0_betti_auc	-0.626	1.37e-08	vertex_count	-0.467	9.76e-06
h0_observed_persistence	-0.613	2.05e-08	edge_density	-0.331	0.0027
transition_entropy	-0.613	2.05e-08	reciprocity	-0.252	0.025

A.3 调制视角

表 13: 调制视角下古典音乐与专注音乐的拓扑特征对比

指标	Median _{Classical}	Median _{Focus}	ϵ^2	180s BH-FDR q	300s BH-FDR q
edge_density	0.667	0.524	0.105	0.00509	0.0423
h0_censored_count	1.000	1.000	0.087	0.00533	0.159
vertex_count	5.000	6.000	0.092	0.00533	0.0396
reciprocity	0.873	0.776	0.078	0.0071	0.0464
edge_count	11.500	14.000	0.051	0.0328	0.0424
h0_betti_max	4.000	5.000	0.035	0.0633	0.0424
h0_betti_mean	2.917	3.583	0.034	0.0633	0.0424
h0_interval_count	4.000	5.000	0.035	0.0633	0.0424
self_transition_ratio	0.448	0.401	0.031	0.0699	0.0928
h0_betti_auc	1.300	1.625	0.028	0.0747	0.0424
h0_observed_persistence	1.450	1.775	0.026	0.0809	0.0424
directed_recurrence	0.130	0.109	0.021	0.1	0.0424
transition_entropy	0.843	0.860	0.010	0.216	0.0424
path_entropy	1.087	1.119	0.000	0.643	0.962
h1_betti_auc	0.000	0.000	0.000	0.683	1
h1_betti_max	0.000	0.000	0.000	0.683	1
h1_betti_mean	0.000	0.000	0.000	0.683	1
h1_censored_count	0.000	0.000	0.000	0.683	1
h1_interval_count	0.000	0.000	0.000	0.683	1
h1_observed_persistence	0.000	0.000	0.000	1	0.453

表 14: 调制视角在主尺度通过独立两两 (Open Focus-Classical) FDR 的指标

指标	rank-biserial	BH-FDR q
edge_density	-0.386	0.00514
h0_censored_count	0.299	0.00539
vertex_count	0.355	0.00539
reciprocity	-0.336	0.00716
edge_count	0.279	0.0331

B 致谢

本研究几乎由我本人独立完成，期间得到了诸位专家和老师的支持，在此表示感谢。

感谢肖天昂老师在统计方法和模型设计上给予的指导。肖老师拥有格拉斯哥大学统计学硕士学位，专注于 Diffusion 模型研究。论文中组间多元统计分析是在肖老师的指导下完成的。当我的 LoRA 方案失败时，是肖老师为我分析原因，带我读论文、找方法，最终我们提出了 LTCH。尽管肖老师日常工作很忙，但还是愿意抽出时间无偿指导我的研究，耐心解答我的问题，还免费提供 L40S 显卡用于模型训练。再次感谢肖老师的帮助！

感谢杨晓安老师在论文写作上的精心指导。作为我的在校导师，杨老师指出了论文中多处繁琐和逻辑不严谨的地方，督促并鼓励我不断推进研究。

最后，特别感谢陈兆君博士和 Kevin J.P. Woods 博士。陈兆君博士是我的学姐，目前在加州理工学院攻读数学博士，主攻方向是代数拓扑。她回校做的一次拓扑学讲座激发了我用拓扑学研究音乐结构的灵感；Woods 博士现任 brain.fm 科学总监，专注于听觉注意力与神经调控。他慷慨地授权 brain.fm 的 focus music 用于本研究，成为此项研究的起点。

C 研究经历

此研究源于我个人对 focus music 的好奇。我本人是 focus music 的重度使用者，一直好奇为什么 focus music 能够帮助我提升专注力，它与其他音乐有何不同？2025 年圣诞假期，我看到 *The role of music in ADHD: A multi-dimensional computational and theoretical analysis* [6] 这篇论文，意识到听觉体验原来是可以数学建模的。于是 2026 年寒假期间，我用 Python 重新实现了这篇论文的分析方法（原论文用 R 语言实现），并在 Spotify 的专注歌单上重新跑了一遍实验。实验结果参见 <https://github.com/fisheryv/focus-music-analysis>。

我不满足于只停留在音频特征层面，我希望进一步了解 focus music 的结构特征。刚好学姐陈兆君博士的拓扑学讲座给了我启发，我计划用拓扑工具分析音乐。我花了两个月时间学习拓扑学基础知识，发现 GLMY 理论可能更适合分析音乐的有向结构。为了获取 focus music 原始音频做研究，我尝试给专门制作 focus music 的 brain.fm 发送授权申请邮件，没想到真的获得了研究授权，于是本研究正式开始。

- 2026 年 4 月 • **完成路径同调分析 Python 库**
在 brain.fm 授权的 focus music 数据集上完成了第一版路径同调分析，这个过程主要完成了路径同调和特征提取的 Python 代码。
- 2026 年 5 月 • **正式对 focus music 展开拓扑特征分析**
由于 brain.fm 授权范围的限制，我用开放数据重新构建了 Open Focus 数据集和 Classical 对照基线，并完成了音高、节奏、调制三个视角的拓扑特征的提取。
- 2026 年 6 月 • **完成拓扑特征分析和融合分析**
对拓扑数据进行统计分析，期间肖老师在统计工具和方法上提出了关键性改进建议。在肖老师的建议下，论文增加融合和消融分析，肖老师还指导了多元统计分析方法。撰写论文数据集和拓扑特征发现与验证部分。
- 2026 年 7 月 • **研究 ACE-Step 和 LoRA**
我以之前的实验为基础，参加了腾讯音乐青少年音乐科技培养项目（MTX）。项目课题是将发现的 focus music 的拓扑特征应用到音乐生成中。这期间，我阅读了 ACE-Step 的代码，学习了 LoRA 的原理，并在我的 3090 显卡上利用 Best-of-N reranking 构造训练数据，训练 LoRA 模型，试图通过这种方式生成满足拓扑特征的音乐，但实验结果验证失败。LoRA 学到的主要是音频特征。我意识到对音乐生成施加拓扑引导似乎没那么简单，于是我向肖老师求助。
- 2026 年 8 月 • **完成 LTCH 训练及效果验证**
肖老师为我分析了 LoRA 失败的原因，并讲解了 Diffusion 和 U-Net 的工作原理。由于端到端扩散引导计算开销巨大，我们选择直接在潜空间预测并控制拓扑特征。为此，肖老师带我精读论文 Low-Resource Guidance for Controllable Latent Audio Diffusion [27]。参照此论文的思想，我们提出了 LTCH。我用 PyTorch 实现了 LTCH，并完成了模型训练和生成效果评估。
- 2026 年 9 月 • **论文撰写与审阅**
使用 Trae + GLM5.3 开发盲评 Web 工具，组织人工盲评。完成整体论文撰写。杨晓安老师在论文结构和学术写作规范上进行了审核和指导。